

DataVis

基于大语言模型的智能数据分析平台

Natural Language Driven Data Analytics Platform

自然语言驱动 智能分析 可视化洞察 公平性评估



数据来源

Census Income (收入预测数据)

<https://archive.ics.uci.edu/dataset/20/census+income>

Adult Census Income 数据集，来自美国1944年人口普查数据，用于预测个人年收入是否超过50K美元

32,561 条记录 15 个特征 无缺失值 二分类目标

课程：Python程序设计

作者：尤浩宇

学号：2025201743

智能分析流程



上传数据



自然语言提问



AI理解意图



自动执行分析




生成可视化结果

01 数据概览

收入分布 (目标变量 col_14)

数据集统计




<=50K (低收入) >50K (高收入)

总样本数	32,561
总特征数	15
缺失值总数	0
内存占用	19.92 MB
高收入占比	24.1%
低收入占比	75.9%

★ 结论：数据集存在明显类别不平衡，高收入样本仅占24.1%，对模型召回率提出挑战

02 模型性能评估 (随机森林)

ROC 曲线 (AUC = 0.8972)




结论：ROC-AUC 达 0.8972，模型具有较强的区分能力。

混淆矩阵



结论：准确率84.66%，但高收入群体召回率仅64.41%，存在误判问题。

03 特征重要性 (随机森林 Top 12)




结论：年龄、教育年限、每周工时是影响收入水平的核心因素，资本收益也起到重要作用。

04 公平性分析 (随机森林)

按种族 (race) 公平性审计

TPR (真正率) FPR (假正率)

TPR 差异: 0.3056 FPR 差异: 0.1014




⚠ 结论：种族维度存在明显偏差，TPR差异超过0.1，美洲印第安/爱斯基摩人群体召回率最低

按性别 (sex) 公平性审计

TPR (真正率) FPR (假正率)

TPR 差异: 0.0862 FPR 差异: 0.0943



✅ 结论：性别维度差异未超过阈值0.1，整体处于可接受范围之内

05 分析方法 (Methodology)



数据探索 (EDA)

数据清洗、分布分析、相关性分析、可视化探索



特征工程

删除不必要特征，对数变换、低频合并、标准化、编码、缺失值填充



模型训练与对比

逻辑回归vs随机森林，5折交叉验证对比



模型评估

准确率、精确率、召回率



解释性分析

随机森林特征重要性



公平性审计

按性别、种族计算PTR、FPR差异，识别潜在偏差

06 主要结论 (Key Conclusions)



模型表现优秀：随机森林 ROC-AUC 达 0.8972，具有较强的区分能力。



类别不平衡导致召回率偏低：高收入群体仅占 24.1%，导致模型召回率仅 64.41%。



教育、年龄、工时是最关键因素：education-num、age、hours-per-week 对高收入预测贡献最高。



种族维度存在显著不公平：TPR 差异 0.3056，Amer-Indian-Eskimo 群体召回率最低。



性别维度差异较小：性别 TPR、FPR 差异均未超过 0.1，整体可接受。



建议：收集更多少数族裔样本，采用公平性约束或后处理方法缓解偏差，提升模型公平性。

07 技术栈 (Tech Stack)

后端技术

Python 3.10+
scikit-learn
pandas
numpy
matplotlib / seaborn
FastAPI
DEEPSEEK API

前端技术

Vue 3
Vite
Pinia
ECharts
Axios
SSE (流式通信)

08 系统架构 (Architecture)



用对话的方式探索数据的价值，让分析更简单，让决策更智能！